

Curso de Python do ZERO AO DS

com Meigarom do canal “Seja Um
Data Scientist”

Instagram:

@meigarom.datascience (Mais
informações sobre o Curso)

LinkedIn: <https://www.linkedin.com/in/meigarom/> (Contato
Profissional)

Telegram: <https://t.me/sejaumdatascientist> (GRUPO DE

ESTUDOS)

Aula 03 - Transformação de Dados I - Básico

Agenda:

- 1. Novas perguntas de negócio.**
- 2. Planejamento da Solução.**

3. Estrutura de Dados.

4. Transformação de Dados.

5. Exercícios Práticos.

1. Novas perguntas de negócio.

1.1. Recapitulando o

desafio: ([https://](https://sejaumdatascientist.com/os-5-projetos-de-data-science-que-fara-o-recrutador-olhar-para-voce/)

sejaumdatascientist.com/os-5-projetos-de-data-science-que-fara-o-recrutador-olhar-para-voce/)

- **EMPRESA:** House Rocket
- **MODELO DE NEGÓCIO:** Compra casas com preço baixo e revendo com o preço mais alto.
- **QUAL O DESAFIO:** Encontrar bons negócios dentro do portfólio disponível, ou seja, encontrar casas com preço baixo, em ótima localização e
que tenham um ótimo potencial de revenda por um preço mais alto.

1.2. Novas perguntas do

CEO para você:

1. Qual o número de imóveis por ano de construção?

2. Qual o menor número de quartos por ano de construção dos imóveis?

3. Qual o preço de compra mais alto por cada número de quartos?

4. Qual a soma de todos os preços de compra por cada número de quartos?

5. Qual a soma de todos

os preços de compra pelo número de quartos e banheiros?

6. Qual o tamanho médio das salas dos imóveis por ano de construção?

7. Qual o tamanho mediano das salas dos imóveis por ano de construção?

8. Qual o desvio-padrão do tamanho das salas dos imóveis por ano de construção?

9. Como é o crescimento

médio preços de compra dos imóveis, por dia e semana do ano?

10. Eu gostaria de olhar no mapa e conseguir identificar as casas com o maior preço.

2. Planejamento da solução:

2.1. Produto Final (O que eu vou entregar? Planilha, gráfico, modelo de ML, ...)

- Email + 2 anexos:
 - Email: As respostas das perguntas.

- Pergunta 1

Resposta

- Anexo 01: Um dashboard com 3 gráfico.
- Anexo 02: A foto de um mapa 2.0 em .html

2.2. Ferramenta (Qual ferramenta usar?)

- Python 3.8.0
- Jupyter Notebook

2.3. Processo (Como fazer?)

1. Qual o número de imóveis por ano de construção?

- Contar o número de ids por ano de construção

2. Qual o menor número de quartos por ano de construção dos imóveis?

- Filtrar todos os imóveis por ano de construção e selecionar o menor número de quartos.

3. Qual o preço de compra mais alto por cada número de quartos?

- Filtrar todos os imóveis por número de quarto e selecionar o maior preço.

4. Qual a soma de todos os preços de compra por cada número de quartos?

- Filtrar todos os imóveis por número de quarto e somar todos os

preços.

5. Qual a soma de todos os preços de compra pelo número de quartos e banheiros?

- Filtrar todos os imóveis por número de quarto e banheiro e somar todos os preços.

6. Qual o tamanho médio das salas dos imóveis por ano de construção?

- Filtrar todos os

imóveis por ano de construção e fazer a média do tamanho das salas.

7. Qual o tamanho mediano das salas dos imóveis por ano de construção?

- Filtrar todos os imóveis por ano de construção e calcular a mediana do tamanho das salas.

8. Qual o desvio-padrão

do tamanho das salas dos imóveis por ano de construção?

- Filtrar todos os imóveis por ano de construção e calcular o desvio-padrão do tamanho das salas.

9. Como é o crescimento médio preços de compra dos imóveis, por dia e semana do ano?

- Filtrar todos os imóveis por data e calcular

o preço médio.

- **Procurar uma Biblioteca em Python que tenha uma Função que desenhe um gráfico de linha.**

- **Aprender a usar a função e desenhar um a variação do preço médio por dia e semana do ano.**

10. Eu gostaria de olhar no mapa e conseguir identificar as casas com o maior preço.

- **Modificar o mapa da entrega anterior fazendo com que o pontos tenham o tamanho dependente do preço.**

3. As ferramentas para criar códigos em Python:

- **IDEs (Interface Development Environment)**
- **PyCharm**

- VSCode**
 - Spyder**
 - JupyterLab**
-
- Notebooks**
 - Jupyter Notebook**

A principal Vantagem e Desvantagem:

- IDE's é sempre necessário transformar TODOS os comandos em linguagem de máquina, todas vez que você executa os arquivo que

contém o seu código.

- Notebook é necessário transformar apenas os comandos escolhidos em linguagem de máquina.

Os notebooks precisam de um “ambiente” para funcionar. Esse

“ambiente” possui:

**- Editor de Texto
(Notebook)**

- O interpretador do Python.

- As bibliotecas que você

está usando.

- O ambiente mais fácil para estudantes é o Anaconda

3.1. Instalando o Anaconda no Windows:

- 80% de vocês vão desistir nesse momento (“Não consigo”, “Tá dando erro”, “Não é pra mim”, ...)

- 10% de vocês vão seguir em frente (Um

problema superado + perto do objetivo)

- 10% de vocês não vão nem tentar (Aqueles que só assistem e não estudam)

■ <https://www.anaconda.com/distribution/#windows>
<https://www.linkedin.com/pulse/tutorial-pr%C3%A1tico-de-como-instalar-anaconda-para-gomes-de-lima>

3.2. Extensões do Anaconda

- conda install -c conda-forge

jupyter_contrib_nbextensions

- Codefolding
- Collapsible Headings
- Code prettify
- Execute Time
- Hide input

4. As estruturas de Dados em Python.

- As 4 estruturas de dados mais usadas em Python são:

- Listas (Mostrarei na próxima aula, Aula 04)
- Dicionários
- Tuples (Mostrarei na próxima aula, Aula 04)
- Dataframes

4.1. Dicionários:

- Armazenam dados na forma de chave-valor e não aceitam duplicados.
- Os dados são armazenados com chave-valor (“nome”: valor)
- Precisam de um

nome.

=====

=====

=====

Dentro do Jupyter Notebook

#

=====

=====

**# Estrutura de Dados -
Dicionário**

#

=====

=====

**# o dicionário tem a
seguinte forma:**

**dict = {'chave01': valor01,
'chave02': valor02,
'chave03': valor03,
'chave04': valor04 }**

**skirt = {'size': 'M', 'price':
139.90, 'color': 'black'}**

**skirt = {'size': 'M', 'price':
139.90, 'color': 'black',**

**'launch_date':
'2020-01-01'}**

skirt = {'size': 'M', 'price':

**139.90, 'color': ['black',
'red', 'white']}]}**

**# acesso aos valores -> via
chave**

skirt['size']

skirt['color'][0]

um dicionário vazio

skirt = {}

Adicionar valores

**# skirt['category'] =
'bottom'**



=====

=====

4.2. Dataframes:

- Armazenam dados na forma tabular com nomes nas linhas e colunas
- Precisam de um nome.

=====

=====

=====

Dentro do Jupyter

Notebook

#

=====

=====

**# Estrutura de Dados -
Dataframes**

#

=====

=====

Um dataframe vazio

df = pd.DataFrame()

#

**# Um dataframe a partir um
dicionário**

```
# data = {'size': ['P', 'M',  
'G'], 'price': [139.90, 89.90,  
29.90], 'color': ['black',  
'red', 'white']}  
# df = pd.DataFrame( data )
```

```
=====
```

```
=====
```

```
=====
```

5. Transformação de Dados:

- Agrupamento
- Operações

matemáticas

5.1. Agrupamento:

- Sequência de 3 tarefas:
Split, Apply, Combine
(**Separa, Aplica, Combina**)

=====

=====

=====

Dentro do Jupyter Notebook

#

=====

=====

Agrupamento

#

=====

=====

#

**print(data[data['bedroom
s'] == 0].shape)**

#

**print(data[data['bedroom
s'] == 1].shape)**

#

**print(data[data['bedroom
s'] == 2].shape)**

```
#  
print( data[ data[ 'bedroom  
s' ] == 3 ].shape )  
#  
print( data[ data[ 'bedroom  
s' ] == 4 ].shape )  
#  
# df_grouped = data[ ['id',  
'bedrooms' ] ].groupby( 'be  
drooms' )  
#  
# Inside of groupby  
# for bedrooms, frame in  
df_grouped:  
#     print( 'Number of
```

bedrooms:

{ }'.format(bedrooms))

**# print(frame.shape,
end='\n\n')**

#

=====

=====

=====

5.2. Operações:

- Com os dados agrupados, podemos realizar operações matemáticas:**
- Exemplos de**

operações matemática:

- Contagem.**
- Mínimo.**
- Máximo.**
- Soma.**
- Média.**
- Mediana.**
- Desvio Padrão.**

6. Executando o PROCESSO planejado:

1. Qual o número de

imóveis por ano de
construção?

- Contar o número de
ids dos imóveis por ano de
construção

Dentro do Jupyter Notebook

Count

```
#df3[['id',  
'yr_built']].groupby( 'yr_bui  
lt' ).count()
```



=====

=====

2. Qual o menor número de quartos por ano de construção dos imóveis?

- Filtrar todos os imóveis por ano de construção e selecionar o menor número de quartos.

Dentro do Jupyter Notebook

Min

```
df3[['bedrooms',  
'yr_built']].groupby( 'yr_bui  
lt' ).min()
```

```
=====
```

```
=====
```

```
=====
```

3. Qual o preço de compra mais altos por cada número de quartos?

- Filtrar todos os imóveis por número de quarto e selecionar o maior preço.

Dentro do Jupyter Notebook

```
# Max  
#df3[['price',  
'bedrooms']].groupby( 'bed  
rooms' ).max()
```

```
=====
```

```
=====
```

```
=====
```

4. Qual a soma de todos

os preços de compra por cada número de quartos?

- Filtrar todos os imóveis por número de quarto e somar todos os preços.

Dentro do Jupyter Notebook

Soma

```
#df3[['price',  
'bedrooms']].groupby( 'bed  
rooms' ).sum()
```

```
=====
=====
=====
```

5. Qual a soma de todos os preços de compra pelo número de quartos e banheiros?

- Filtrar todos os imóveis por número de quarto e banheiro e somar todos os preços.

Dentro do Jupyter

Notebook

```
#df3[['price', 'bedrooms',  
'bathrooms']].groupby( ['be  
drooms',  
'bathrooms'] ).sum()  
#df3[['price', 'bedrooms',  
'bathrooms']].groupby( ['ba  
throoms',  
'bedrooms'] ).sum()
```

```
=====
```

```
=====
```

```
=====
```

6. Qual o tamanho médio

das salas dos imóveis por ano de construção?

- Filtrar todos os imóveis por ano de construção e fazer a média do tamanho das salas.

Dentro do Jupyter Notebook

```
# Media
```

```
#df3[['sqft_living',  
'yr_built']].groupby( 'yr_built' ).mean()
```

```
#df3[['sqft_living',
```



```
'bedrooms',  
'yr_built']].groupby( ['yr_bu  
ilt', 'bedrooms'] ).mean()
```

```
=====
```

```
=====
```

```
=====
```

**7. Qual o tamanho
mediano das salas dos
imóveis por ano de
construção?**

**- Filtrar todos os
imóveis por ano de
construção e calcular a**

mediana do tamanho das salas.

Dentro do Jupyter Notebook

Mediana

```
#df3[['sqft_living',  
'yr_built']].groupby( 'yr_built' ).median()
```

```
#df3[['sqft_living',  
'bedrooms',  
'yr_built']].groupby( ['yr_built', 'bedrooms'] ).median()
```

----- Bonus -----

```
#df3[['sqft_living',  
'bedrooms',  
'yr_built']].groupby( ['yr_bu  
ilt',  
'bedrooms'] ).agg( ['max',  
'min', 'mean', 'median'] )
```

=====

=====

=====

**8. Qual o desvio-padrão
do tamanho das salas dos**

imóveis por ano de construção?

- Filtrar todos os imóveis por ano de construção e calcular o desvio-padrão do tamanho das salas.

Dentro do Jupyter Notebook

```
# Desvio Padrao  
#df3[['sqft_living',  
'yr_built']].groupby( 'yr_built' ).std()
```

```
#df3[['sqft_living',  
'bedrooms',  
'yr_built']].groupby( ['yr_bu  
ilt', 'bedrooms'] ).std()
```

```
=====
```

```
=====
```

```
=====
```

9. Como é o crescimento médio preços de compra dos imóveis, por dia, mês e ano?

- Filtrar todos os imóveis por data e calcular

o preço médio.

- Procurar uma Biblioteca em Python que tenha uma Função que desenhe um gráfico de linha.

- Aprender a usar a função e desenhar um a variação do preço médio por dia e semana do ano.

**Dentro do Jupyter
Notebook -
ORIGINAL**

First Graph

```
df['year'] =  
pd.to_datetime( df['date'] ).  
dt.year  
by_year = df[['id',  
'year']].groupby( 'year' ).me  
an().reset_index()  
plt.figure( figsize=(20,10))  
plt.bar( by_year['year'],  
by_year['id'] )
```

Second Graph

```
df['day'] =  
pd.to_datetime( df['date'] )  
by_day = df[['id',
```

```
'day']].groupby( 'day' ).mean()  
n().reset_index()  
plt.figure( figsize=(20,10))  
plt.plot( by_day['day'],  
by_day['id'] )
```

Thrid Graph

```
df['year_week'] =  
pd.to_datetime( df['date'] ).  
dt.strftime( '%Y-%U')  
by_week_of_year = df[['id',  
'year_week']].groupby( 'year_week' ).mean().reset_index()  
plt.figure( figsize=(20,10))
```



```
plt.plot( by_week_of_year['  
year_week'],  
by_week_of_year['id'] )  
plt.xticks( rotation=60 );
```

DASHBOARD

```
from matplotlib import  
pyplot as plt  
from matplotlib import  
gridspec  
fig = plt.figure( figsize=(24,  
12) )  
specs =  
gridspec.GridSpec( ncols=
```

2, nrow=2, figure=fig)

ax1 =

**fig.add_subplot(specs[0, :
]) # First Row**

ax2 =

**fig.add_subplot(specs[1,
0]) # First Row First
Column**

ax3 =

**fig.add_subplot(specs[1,
1]) # Second Row First
Column**

Frist Graph

```
df['year'] =  
pd.to_datetime( df['date'] ).  
dt.year  
by_year = df[['id',  
'year']].groupby( 'year' ).su  
m().reset_index()  
ax1.bar( by_year['year'],  
by_year['id'] )  
ax1.set_title( "Title: Sum  
Price by Year" )
```

Second Graph

```
df['day'] =  
pd.to_datetime( df['date'] )
```

```
by_day = df[['id',  
'day']].groupby( 'day' ).mean()  
.reset_index()  
ax2.plot( by_day['day'],  
by_day['id'] )  
ax2.set_title( "Title:  
Average Price by Day" )
```

Thrid Graph

```
df['year_week'] =  
pd.to_datetime( df['date'] ).  
dt.strftime( '%Y-%U')  
by_week_of_year = df[['id',  
'year_week']].groupby( 'year_week' ).mean().reset_ind
```

```
ex()  
ax3.plot( by_week_of_year  
['year_week'],  
by_week_of_year['id'] )  
plt.xticks( rotation=60 );
```

```
=====
```

```
=====
```

```
=====
```

**10. Eu gostaria de olhar
no mapa e conseguir
identificar as casas com o
maior preço.**

- Modificar o mapa da

entrega anterior fazendo
com que o pontos tenham
o tamanho dependente do
preço.

Dentro do Jupyter Notebook

```
import plotly.express as px
houses = df3[['id', 'lat',
'long', 'price']]
fig =
px.scatter_mapbox( house
s,
lat="lat",
```

```
lon="long",  
  
size="price",  
  
color_continuous_scale=p  
x.colors.cyclical.IceFire,  
  
size_max=15,  
zoom=10)  
  
fig.update_layout(mapbox  
_style="open-street-map")  
fig.update_layout(height=6  
00,  
margin={"r":0,"t":0,"l":0,"b
```

```
" :0})  
fig.show()
```

```
mapa.write_html( 'datasets  
/  
mapa_house_rocket.html' )
```

```
=====
```

```
=====
```

```
=====
```

7. Exercícios:

Novas perguntas do CEO

para você:

1. Crie uma nova coluna chamada:

“dormitory_type”

- Se o valor da coluna “bedrooms” for igual à 1 => ‘studio’

- Se o valor da coluna “bedrooms” for igual a 2 => ‘apartament’

- Se o valor da coluna “bedrooms” for maior que 2 => ‘house’

2. Faça um gráfico de

barras que represente a soma dos preços pelo número de quartos.

3. Faça um gráfico de linhas que represente a média dos preços pelo ano construção dos imóveis.

4. Faça um gráfico de barras que represente a média dos preços pelo tipo dos dormitórios.

5. Faça um gráfico de

linha que mostre a evolução da média dos preços pelo ano da reforma dos imóveis, a partir do ano de 1930.

6. Faça um tabela que mostre a média dos preços por ano de construção e tipo de dormitórios dos imóveis.

7. Crie um Dashboard com os gráficos das

**questões 02, 03, 04
(Dashboard: 1 Linha e 2
colunas)**

**8. Crie um Dashboard
com os gráficos das
perguntas 02, 04
(Dashboard: 2 colunas)**

**9. Crie um Dashboard
com os gráficos das
perguntas 03, 05
(Dashboard: 2 Linhas)**

10. Faça um gráfico com

**o tamanho dos pontos
sendo igual ao tamanho da
sala de estar**